

T-RAG v2: Selective Multi-Source Retrieval-Augmented Generation

Hệ thống RAG doanh nghiệp phân tách nguồn thông minh với Adaptive Tau & Smart Hop 2

Trình bày: Đăng Bảo & Đình Bằng

Tháng 7, 2026

Nội dung báo cáo

- 1 Bối cảnh & Phát biểu Bài toán
- 2 Đóng góp Kỹ thuật Cốt lõi của T-RAG v2
- 3 Kiến trúc Pipeline T-RAG v2
- 4 Thực nghiệm & Kết quả Benchmark (53 Cấu hình)

Thách thức: RAG trên Dữ liệu Doanh nghiệp

Bộ dữ liệu thử nghiệm: EnterpriseRAG-Bench

- **4,213,106 tài liệu (chunks)** phân tán trên 9 nguồn dữ liệu doanh nghiệp.
- Slack, Gmail, Jira, Confluence, GitHub, Fireflies, HubSpot, Linear, GDrive.
- **500 câu hỏi đánh giá** thuộc 10 dạng câu hỏi doanh nghiệp thực tế.
- Nhiều thông tin: Xung đột ngữ nghĩa, thuật ngữ mã nguồn, ID ticket.

3 Hạn chế cốt lõi của Standard RAG

- ❶ **Mơ hồ nguồn (Source Ambiguity):** Quét toàn cục gây nhiễu và phòng không gian vector.
- ❷ **Bất đồng nhất từ vựng (Vocabulary Mismatch):** Thuật ngữ kỹ thuật (Jira ID, PR #, branch) bị Vector Search bỏ sót (Vector Baseline chỉ đạt 19.6%).
- ❸ **Lập luận đa nguồn (Multi-source Hop):** Đòi hỏi liên kết thông tin chéo nguồn mà 1 lượt search không đáp ứng được.

T-RAG v2 được thiết kế để giải quyết cả 3 thách thức trên với tốc độ và độ chính xác tối ưu.

Các Đóng góp Kỹ thuật Cốt lõi trong T-RAG v2

#1 — PSR Router + Adaptive Tau

Tự động điều chỉnh ngưỡng

$\tau_{eff} = \tau_{base} + \alpha \cdot (conf - 0.5)$ theo độ tự tin của Router. Giảm không gian tìm kiếm từ **36% đến 67%**.

#2 — Sửa lỗi Double-Encode (Tăng tốc 6x)

Tái sử dụng vector embedding giữa Hop 1 và Hop 2, kéo Retrieval Latency từ **1.68s** xuống còn **0.27s**.


#3 — Cơ chế Smart Hop 2 (Conditional)

Bỏ qua Hop 2 nếu câu hỏi đơn nguồn ($active_shards < 2$) hoặc Hop 1 đã rất khớp ($top1_dist < 0.55$), tiết kiệm **34% Total Latency**.

#4 — SW-RRF + Hybrid Search Tuning

Tăng trọng số BM25 trên từ khóa kỹ thuật ($D = 0.3, S = 0.7$) kết hợp với Bayesian Prior $P(Source|Q)^\gamma$.

Tổng quan Pipeline T-RAG v2 (End-to-End)



Stage 1: PSR Router & Lý thuyết Adaptive Tau

Công thức PSR Router (Logistic Regression):

$$P(s_i|Q) = \sigma(W_i \cdot \text{Encoder}(Q) + b_i)$$

Thuật toán Adaptive Tau (Dynamic Thresholding):

- 1 Shannon Entropy: $H = -\sum_{i=1}^K n_i \ln(n_i + 1e^{-10})$, với $n_i = p_i / \sum p_k$
- 2 Confidence: $conf = 1.0 - \frac{H}{\ln(K)}$ ($K = 9$ shards)
- 3 Ngưỡng hiệu dụng τ_{eff} :

$$\tau_{eff} = \tau_{base} + \alpha \cdot (conf - 0.5)$$

kẹp an toàn trong khoảng $[0.05, 0.40]$.

Tự điều chỉnh theo loại câu hỏi

- **Câu hỏi rõ nguồn:** Router dự đoán xác suất tập trung vào 1 shard $\rightarrow H$ thấp $\rightarrow conf$ cao $\rightarrow \tau_{eff}$ tăng lên $\rightarrow$ **Chỉ quét 1 Shard**.
- **Câu hỏi mơ hồ:** Xác suất san đều $\rightarrow H$ cao $\rightarrow conf$ thấp $\rightarrow \tau_{eff}$ hạ xuống $\rightarrow$ **Mở rộng quét 3-4 Shards** để bảo toàn Recall.

Ví dụ Tính toán (1/2): PSR Router & Chuẩn hóa Phân phối

Câu hỏi truy vấn (Q): "Có ticket Jira nào liên quan đến lỗi out of memory của cổng OpenAI API được nhắc đến trên Slack không?"

Bước 1: Dự đoán xác suất PSR $P(s_i|Q)$

Sigmoid Logistic Regression dự đoán xác suất từng Shard chứa câu trả lời:

- $P(\text{slack}|Q) = 0.85$ (Slack)
- $P(\text{jira}|Q) = 0.75$ (Jira)
- $P(\text{github}|Q) = 0.12$ (GitHub)
- $P(\text{confluence}|Q) = 0.05$ (Confluence)
- Các nguồn khác (gmail, gdrive...): ≤ 0.02

Bước 2: Phân phối chuẩn hóa $n_i = p_i/S$

Tính tổng xác suất $S = \sum_{i=1}^9 p_i = 1.83$ và chuẩn hóa về phân phối đơn vị n_i :

- $n_{\text{slack}} = 0.85/1.83 = 0.464$
- $n_{\text{jira}} = 0.75/1.83 = 0.410$
- $n_{\text{github}} = 0.12/1.83 = 0.066$
- $n_{\text{confluence}} = 0.05/1.83 = 0.027$
- $n_{\text{khác}} \leq 0.011$ ($\sum_{i=1}^9 n_i = 1.0$)

Ví dụ Tính toán (2/2): Adaptive Tau & Chọn Active Shards

Bước 3: Tính toán Adaptive Tau

1 Shannon Entropy:

$$H = - \sum_{i=1}^9 n_i \ln n_i \approx 1.25$$

2 Entropy tối đa: $H_{max} = \ln(9) \approx 2.197$

3 Hệ số tự tin (Confidence):

$$conf = 1.0 - \frac{1.25}{2.197} = 0.431$$

4 Ngưỡng hiệu dụng τ_{eff} :

$$\tau_{eff} = 0.15 + 0.08 \times (0.431 - 0.5) = 0.1445$$

Ý nghĩa Tham số

($\tau_{base} = 0.15, \alpha = 0.08$)

- $\tau_{base} = 0.15$: Ngưỡng định tuyến cơ sở được tối ưu qua Grid Search.
- $\alpha = 0.08$: Hệ số điều chỉnh biên độ (± 0.04). Vì Router mơ hồ ($conf = 0.431 < 0.5$), τ_{eff} tự động hạ từ $0.15 \rightarrow 0.1445$ để mở rộng khung quét.

Kết quả Chọn Active Shards ($P \geq 0.1445$)

→ Active Shards: {slack, jira} (2/9 shards).
Đóng bằng 7/9 shards, tiết kiệm **75% Search Space!**

Thực nghiệm Router: Routing Hit Rate vs. Active Shards

Ngưỡng Tau (τ)	Routing Hit Rate (%)	Avg. Active Shards
0.10	97.9%	6.82 / 9
0.15	94.9%	5.83 / 9
0.20	91.7%	4.98 / 9
0.25	88.5%	4.24 / 9
0.30	84.0%	3.62 / 9
0.40	76.2%	2.64 / 9
0.50	64.3%	1.93 / 9

Bảng: Bảng đánh giá Tradeoff giữa Routing Hit Rate và Không gian Shard kích hoạt.

Insight về Điểm Cân Bằng (Sweet Spot)

- Ở $\tau = 0.10$: Hit Rate đạt cực cao **97.9%** (bỏ sót chưa tới 2.1% đáp án), đồng thời cắt giảm bớt 2.18 shards không cần thiết.
- Ở $\tau = 0.15$: Hit Rate đạt **94.9%**, giảm gần 40% số shards cần quét (quét trung bình 5.83/9 shards).
- Nếu $\tau \geq 0.40$: Hit Rate sụt giảm nghiêm trọng ($< 76\%$), gây mất ngữ cảnh đáp án.

Stage 2 & 3: Local Hybrid Search, SW-RRF & Smart Hop 2

SW-RRF Fusion & Hybrid Search

$$\text{Score}(d) = P(s_d|Q)^\gamma \cdot \left(\frac{W_{\text{dense}}}{k + r_{\text{dense}}} + \frac{W_{\text{sparse}}}{k + r_{\text{sparse}}} \right)$$

- **Dense Search:** LanceDB IVF-PQ index.
- **Sparse Search:** BM25 Tantivy FTS.
- Trọng số tối ưu: $W_{\text{dense}} = 0.3$, $W_{\text{sparse}} = 0.7$.
- Bayesian Prior $\gamma = 0.4 \div 0.5$: Ưu tiên shard có xác suất Router cao.

Smart Hop 2 Decision (2 Điều kiện SKIP)

- ❶ **Đơn nguồn:** $\text{active_shards_count} < 2 \rightarrow \text{SKIP Hop 2.}$
- ❷ **Match Hop 1 xuất sắc:** $\text{top1_dist} < 0.55 \rightarrow \text{SKIP Hop 2.}$

Ví dụ tiếp tục (Q ví dụ trên):

- $\text{active_shards} = 2 \geq 2$ (Chưa SKIP1).
- $\text{top1_dist} = 0.58 \geq 0.55$ (Chưa SKIP2).
- $\rightarrow$ **TRIGGER Hop 2:** Trích xuất thực thể "SDK-402, OpenAI API" qua LLM $\rightarrow$ Tìm thêm được PR Link liên quan trên Jira.

Bảng 1: So sánh T-RAG v2 với các Baselines

Pipeline / Model	Correctness	Completeness	Combined	Refused	Total Lat	Retr Lat	Search Space
Vector Baseline	19.60%	30.24%	16.47	32.0%	0.60s	0.20s	4,213,106
Vector + Reranker Baseline	24.65%	33.84%	20.89	26.8%	0.69s	0.23s	4,213,106
LLM Router Baseline	27.80%	38.57%	23.96	21.8%	0.88s	0.32s	2,075,036
BM25 Baseline	29.20%	39.50%	25.23	23.0%	0.97s	0.41s	4,213,106
Query Expansion Baseline	32.60%	43.14%	28.34	19.8%	2.46s	1.91s	4,213,106
HyDE Baseline	33.00%	42.97%	28.01	18.2%	1.23s	0.63s	4,213,106
HYBRID Baseline (BM25+Vec+Rerank)	33.60%	44.11%	29.35	18.0%	1.15s	0.63s	4,213,106
T-RAG v2 Standard	34.67%	44.91%	30.72	17.0%	0.84s	0.27s	2,711,818

Bảng: Insight 1: BM25/Hybrid vượt trội hơn hẳn Pure Vector trên dữ liệu doanh nghiệp; LLM Router (27.80%) bị suy giảm độ chính xác nghiêm trọng do định tuyến sai shard gây mất hoàn toàn ngữ cảnh.

Bảng 2: Tác động của Trọng số Hybrid (D_{dense} vs. S_{sparse})

Cấu hình Trọng số	Correctness	Completeness	Combined	Refused	Total Lat	Retr Lat	Search Space
Dense Only ($D = 1.0, S = 0.0$)	24.25%	34.66%	21.11	26.2%	0.82s	0.25s	2,705,415
Hybrid ($D = 0.7, S = 0.3$)	28.26%	37.18%	24.34	24.0%	0.82s	0.26s	2,704,805
Hybrid ($D = 0.5, S = 0.5$)	34.67%	44.91%	30.72	17.0%	0.84s	0.27s	2,711,818
T-RAG v2 ($D = 0.4, S = 0.6$)	36.00%	46.65%	32.01	18.0%	0.89s	0.31s	2,706,057
T-RAG v2 ($D = 0.3, S = 0.7$)	36.80%	45.67%	32.24	17.2%	1.02s	0.43s	3,577,666
Sparse Only ($D = 0.0, S = 1.0$)	33.20%	43.77%	29.88	20.0%	1.07s	0.48s	2,691,477

Bảng: Insight 2: Dữ liệu doanh nghiệp chứa nhiều thực thể mã nguồn (Jira ID, PR #, branch name) đòi hỏi khớp từ khóa BM25 chính xác. Cấu hình $D = 0.3, S = 0.7$ đạt độ chính xác cao nhất (36.80%).

Bảng 3: Tối ưu Latency: Smart Hop 2 & Double-Encode

Cấu hình Ablation	Correctness	Completeness	Combined	Refused	Total Lat	Retr Lat	Search Space
T-RAG v1 Balanced	32.40%	42.56%	27.91	19.2%	1.05s	1.53s	2,372,449
Ablation: No CSEP (Hop 2 OFF)	34.67%	44.38%	30.13	18.2%	0.82s	0.25s	2,704,197
Ablation: No Smart Hop 2 (Luôn Hop 2)	32.80%	43.93%	29.39	18.6%	1.16s	0.58s	2,681,805
T-RAG v2 Standard (Smart Hop 2 BẬT)	34.67%	44.91%	30.72	17.0%	0.84s	0.27s	2,711,818

Bảng: Insight 3: T-RAG v2 Standard tối ưu toàn diện so với No CSEP: Đạt Completeness cao hơn (44.91% vs 44.38%) và giảm Tỷ lệ từ chối (17.0% vs 18.2%) nhờ khả năng mở rộng truy vấn đa nguồn. Smart Hop 2 giúp tiết kiệm 34% latency so với việc luôn bật Hop 2.

Bảng 4: Phân tích Adaptive Tau & Bayesian Prior (γ)

Kịch bản Grid Search	Correctness	Completeness	Combined	Refused	Total Lat	Retr Lat	Search Space
T-RAG v2 ($\tau = 0.05, \gamma = 0.5$)	36.07%	44.97%	31.24	17.4%	0.90s	0.33s	3,573,824
T-RAG v2 ($\tau = 0.10, \gamma = 0.5$)	36.67%	44.99%	31.94	18.4%	0.88s	0.29s	3,323,143
T-RAG v2 ($\tau = 0.15, \gamma = 0.5$)	34.67%	44.91%	30.72	17.0%	0.84s	0.27s	2,711,818
T-RAG v2 ($\tau = 0.30, \gamma = 0.5$)	33.27%	42.91%	29.33	18.0%	0.74s	0.18s	1,456,839
T-RAG v2 ($\gamma = 0.0, \tau = 0.15$)	36.40%	45.52%	31.86	17.0%	0.84s	0.25s	2,706,836
T-RAG v2 ($\gamma = 0.4, \tau = 0.15$)	36.47%	45.23%	31.29	18.4%	0.83s	0.25s	2,706,911
T-RAG v2 ($\gamma = 1.0, \tau = 0.15$)	34.87%	42.32%	29.71	19.0%	0.83s	0.27s	2,704,042

Bảng: Insight 4: Ngưỡng $\tau = 0.10$ và hệ số phạt nguồn $\gamma = 0.4 \div 0.5$ đạt điểm cân bằng tối ưu giữa độ chính xác và tiết kiệm dung lượng quét đĩa.

Bảng 5: Top T-RAG v2

#	Pipeline / Cấu hình	Correctness	Completeness	Combined	Refused	Total Lat	Retr Lat	Search Space
1	[Top 1] T-RAG v2 ($\tau = 0.05, \gamma = 0.5, D = 0.3, S = 0.7$)	36.80%	45.67%	32.24	17.2%	1.02s	0.43s	3,577,666
2	[Top 2] T-RAG v2 ($\tau = 0.10, \gamma = 0.5, D = 0.5, S = 0.5$)	36.67%	44.99%	31.94	18.4%	0.88s	0.29s	3,323,143
3	[Top 3] T-RAG v2 ($\tau = 0.15, \gamma = 0.4, D = 0.5, S = 0.5$)	36.47%	45.23%	31.29	18.4%	0.83s	0.25s	2,706,911
4	T-RAG v2 ($\tau = 0.15, \gamma = 0.0, D = 0.5, S = 0.5$)	36.40%	45.52%	31.86	17.0%	0.84s	0.25s	2,706,836
5	T-RAG v2 ($\tau = 0.15, \gamma = 0.5, \alpha = 0.15, D = 0.5, S = 0.5$)	36.27%	45.47%	31.84	17.8%	0.86s	0.28s	3,006,387
–	HYBRID Baseline	33.60%	44.11%	29.35	18.0%	1.15s	0.63s	4,213,106

Bảng: Insight 5: Top cấu hình T-RAG v2 cải thiện +3.2 điểm % Correctness so với HYBRID Baseline tốt nhất đồng thời tiết kiệm 36% không gian quét dữ liệu.

Kết luận & Hướng phát triển

Kết luận

- T-RAG v2 giải quyết triệt để các hạn chế về latency và độ chính xác của RAG doanh nghiệp.
- Tối ưu hóa **Smart Hop 2** và **Double-Encode** giúp giảm Retrieval Latency xuống **0.27s** (nhanh gấp 6x).
- Cấu hình với trọng số $D = 0.3, S = 0.7$ đạt đỉnh hiệu năng với **36.80% Correctness**.
- Xuất bản bộ dữ liệu Benchmark EnterpriseRAG-Bench cùng 53 cấu hình thực nghiệm làm cơ sở tham chiếu cho cộng đồng.

Định hướng phát triển

- Thử nghiệm mô hình Router nâng cao trên các kiến trúc mã hóa đa ngôn ngữ (Multilingual).
- Tối ưu hóa prompt trích xuất thực thể để giảm thiểu nhiễu trong Hop 2.
- Đánh giá trên các môi trường sản xuất thực tế với độ trễ thời gian thực.

- ❶ Qiao et al. (2024). *Route Before Retrieve: A New Paradigm for Retrieval-Augmented Generation*.
- ❷ Wang et al. (2024). *RAGRouter: Learning to Route in Retrieval-Augmented Generation*. NeurIPS 2024.
- ❸ Cormack, G. V., Clarke, C. L., & Büttcher, S. (2009). *Reciprocal rank fusion outperforms Condorcet and individual rank learning methods*. ACM SIGIR.
- ❹ Tang et al. (2024). *MultiHop-RAG: Benchmarking Retrieval-Augmented Generation for Multi-Hop Queries*. arXiv:2401.15391.
- ❺ Zhang et al. (2025). *HopRAG: Multi-Hop Reasoning for Logic-Aware Retrieval-Augmented Generation*. arXiv:2502.12442.

Phụ lục (1/4): Bảng Master Kết quả (Cấu hình 1 – 15)

#	Pipeline / Cấu hình	Thông số Cấu hình Details	Corr%	Comp%	Combined	Refused	Total Lat	Retr Lat	Search Space
1	OPT: High Recall + Sparse Heavy	$\tau = 0.05, \gamma = 0.5, \alpha = 0.08, D = 0.3/S = 0.7$, CSEP, SmartHop2	36.80%	45.67%	32.24	17.2%	1.02s	0.43s	3,577,666
2	Grid Tau=0.10	$\tau = 0.10, \gamma = 0.5, \alpha = 0.08, D = 0.5/S = 0.5$, CSEP, SmartHop2	36.67%	44.99%	31.94	18.4%	0.88s	0.29s	3,323,143
3	OPT: Gamma=0.4	$\tau = 0.15, \gamma = 0.4, \alpha = 0.08, D = 0.5/S = 0.5$, CSEP, SmartHop2	36.47%	45.23%	31.29	18.4%	0.83s	0.25s	2,706,911
4	Grid Gamma=0.0	$\tau = 0.15, \gamma = 0.0, \alpha = 0.08, D = 0.5/S = 0.5$, CSEP, SmartHop2	36.40%	45.52%	31.86	17.0%	0.84s	0.25s	2,706,836
5	Grid Alpha=0.15	$\tau = 0.15, \gamma = 0.5, \alpha = 0.15, D = 0.5/S = 0.5$, CSEP, SmartHop2	36.27%	45.47%	31.84	17.8%	0.86s	0.28s	3,006,387
6	Grid Alpha=0.50	$\tau = 0.15, \gamma = 0.5, \alpha = 0.50, D = 0.5/S = 0.5$, CSEP, SmartHop2	36.07%	44.99%	31.40	17.4%	0.90s	0.33s	3,573,824
7	Grid Tau=0.05	$\tau = 0.05, \gamma = 0.5, \alpha = 0.08, D = 0.5/S = 0.5$, CSEP, SmartHop2	36.07%	44.97%	31.24	17.4%	0.90s	0.33s	3,573,824
8	OPT: D=0.4/S=0.6	$\tau = 0.15, \gamma = 0.5, \alpha = 0.08, D = 0.4/S = 0.6$, CSEP, SmartHop2	36.00%	46.65%	32.01	18.0%	0.89s	0.31s	2,706,057
9	Targeted D: Alpha Sweet Spot	$\tau = 0.05, \gamma = 0.4, \alpha = 0.15, D = 0.4/S = 0.6$, CSEP, SmartHop2	36.00%	45.32%	31.10	17.2%	0.96s	0.36s	3,566,845
10	Grid Dense=0.3	$\tau = 0.15, \gamma = 0.5, \alpha = 0.08, D = 0.3/S = 0.7$, CSEP, SmartHop2	35.80%	45.61%	31.85	18.6%	0.92s	0.36s	2,687,974
11	Grid Alpha=0.00	$\tau = 0.15, \gamma = 0.5, \alpha = 0.00, D = 0.5/S = 0.5$, CSEP, SmartHop2	35.67%	44.19%	30.69	18.0%	0.82s	0.25s	2,393,189
12	OPT: Best Completeness	$\tau = 0.15, \gamma = 0.5, \alpha = 0.04, D = 0.3/S = 0.7$, CSEP, SmartHop2	35.60%	45.84%	31.38	19.8%	0.91s	0.33s	2,540,258
13	Targeted G: Minimalist Best	$\tau = 0.10, \gamma = 0.4, \alpha = 0.15, D = 0.3/S = 0.7$, CSEP, SmartHop2	35.60%	45.87%	31.24	17.0%	0.99s	0.40s	3,558,410
14	Grid Tau=0.20	$\tau = 0.20, \gamma = 0.5, \alpha = 0.08, D = 0.5/S = 0.5$, CSEP, SmartHop2	35.47%	44.50%	30.63	18.0%	0.80s	0.23s	2,219,777
15	Grid Alpha=0.12	$\tau = 0.15, \gamma = 0.5, \alpha = 0.12, D = 0.5/S = 0.5$, CSEP, SmartHop2	35.27%	44.64%	31.00	17.8%	0.84s	0.27s	2,853,707

Phụ lục (2/4): Bảng Master Kết quả (Cấu hình 16 – 30)

#	Pipeline / Cấu hình	Thông số Cấu hình Details	Corr%	Comp%	Combined	Refused	Total Lat	Retr Lat	Search Space
16	Ablation: No AdaptTau	$\tau = 0.15, \gamma = 0.5, \alpha = 0.00$ (forced), CSEP, SmartHop2	35.27%	44.27%	30.48	18.0%	0.82s	0.24s	2,393,189
17	OPT: Low Latency	$\tau = 0.20, \gamma = 0.3, \alpha = 0.00, D = 0.5/S = 0.5$, CSEP, SmartHop2	35.27%	43.71%	30.21	19.0%	0.76s	0.20s	1,964,143
18	OPT: Speed+Sparse	$\tau = 0.20, \gamma = 0.5, \alpha = 0.00, D = 0.3/S = 0.7$, CSEP, SmartHop2	35.20%	44.65%	30.68	18.4%	0.85s	0.27s	1,944,632
19	OPT: Balanced	$\tau = 0.15, \gamma = 0.5, \alpha = 0.04, D = 0.5/S = 0.5$, CSEP, SmartHop2	35.07%	45.21%	30.89	18.6%	0.83s	0.26s	2,562,116
20	Grid Alpha=0.04	$\tau = 0.15, \gamma = 0.5, \alpha = 0.04, D = 0.5/S = 0.5$, CSEP, SmartHop2	35.07%	45.20%	30.77	18.6%	0.83s	0.26s	2,562,116
21	Grid Alpha=0.25	$\tau = 0.15, \gamma = 0.5, \alpha = 0.25, D = 0.5/S = 0.5$, CSEP, SmartHop2	34.87%	44.37%	30.62	17.2%	0.90s	0.32s	3,416,644
22	Grid Gamma=1.0	$\tau = 0.15, \gamma = 1.0, \alpha = 0.08, D = 0.5/S = 0.5$, CSEP, SmartHop2	34.87%	42.32%	29.71	19.0%	0.83s	0.27s	2,704,042
23	OPT: D=0.2/S=0.8	$\tau = 0.15, \gamma = 0.5, \alpha = 0.08, D = 0.2/S = 0.8$, CSEP, SmartHop2	34.80%	45.08%	30.83	18.8%	0.97s	0.39s	2,693,001
24	T-RAG v2 Standard	$\tau = 0.15, \gamma = 0.5, \alpha = 0.08, D = 0.5/S = 0.5$, CSEP, SmartHop2	34.67%	44.91%	30.72	17.0%	0.84s	0.27s	2,711,818
25	Ablation: No CSEP	$\tau = 0.15, \gamma = 0.5, \alpha = 0.08, D = 0.5/S = 0.5$, No CSEP, SmartHop2	34.67%	44.38%	30.13	18.2%	0.82s	0.25s	2,704,197
26	Grid Dense=0.1	$\tau = 0.15, \gamma = 0.5, \alpha = 0.08, D = 0.1/S = 0.9$, CSEP, SmartHop2	34.60%	45.13%	30.67	17.8%	1.02s	0.42s	2,690,576
27	Targeted H: Speed King v2	$\tau = 0.15, \gamma = 0.0, \alpha = 0.00, D = 0.4/S = 0.6$, CSEP, SmartHop2	34.60%	43.75%	30.32	19.0%	0.84s	0.26s	2,387,237
28	OPT: Retrieve Depth=30	$\tau = 0.15, \gamma = 0.5, \alpha = 0.08, R = 30, K = 5$, CSEP, SmartHop2	34.47%	44.42%	30.38	16.8%	0.92s	0.34s	2,707,042
29	Grid Gamma=0.3	$\tau = 0.15, \gamma = 0.3, \alpha = 0.08, D = 0.5/S = 0.5$, CSEP, SmartHop2	34.47%	44.54%	30.19	18.0%	0.82s	0.25s	2,706,695
30	Grid Gamma=0.7	$\tau = 0.15, \gamma = 0.7, \alpha = 0.08, D = 0.5/S = 0.5$, CSEP, SmartHop2	34.07%	44.39%	29.84	17.6%	0.83s	0.25s	2,698,037

Phụ lục (3/4): Bảng Master Kết quả (Cấu hình 31 – 45)

#	Pipeline / Cấu hình	Thông số Cấu hình Details	Corr%	Comp%	Combined	Refused	Total Lat	Retr Lat	Search Space
31	OPT: Best Correctness	$\tau = 0.15, \gamma = 0.5, \alpha = 0.25, D = 0.1/S = 0.9$, CSEP, SmartHop2	34.00%	44.03%	29.67	19.2%	1.07s	0.47s	3,392,562
32	T-RAG v1 High-Recall G1	$\tau = 0.05, \gamma = 1.0$, No CSEP, No AdaptTau	33.80%	43.43%	29.71	22.6%	1.19s	2.31s	3,550,005
33	T-RAG v1 Balanced G1	$\tau = 0.15, \gamma = 1.0$, No CSEP, No AdaptTau	33.80%	43.29%	29.66	20.6%	1.02s	1.48s	2,354,016
34	OPT: High Speed Sparse Heavy	$\tau = 0.30, \gamma = 0.5, \alpha = 0.08, D = 0.1/S = 0.9$, CSEP, SmartHop2	33.60%	44.77%	29.52	19.8%	0.86s	0.29s	1,438,218
35	Hybrid Baseline	BM25 + Vector Hybrid, Reranker, K=5	33.60%	44.11%	29.35	18.0%	1.15s	0.63s	4,213,106
36	Grid Tau=0.30	$\tau = 0.30, \gamma = 0.5, \alpha = 0.08, D = 0.5/S = 0.5$, CSEP, SmartHop2	33.27%	42.91%	29.33	18.0%	0.74s	0.18s	1,456,839
37	Sparse Only	$\tau = 0.15, \gamma = 0.5, \alpha = 0.08, D = 0.0/S = 1.0$, CSEP, SmartHop2	33.20%	43.77%	29.88	20.0%	1.07s	0.48s	2,691,477
38	OPT: Max Performance	$\tau = 0.10, \gamma = 0.5, \alpha = 0.04, D = 0.1/S = 0.9$, CSEP, SmartHop2	33.20%	43.67%	29.17	18.8%	1.04s	0.45s	3,100,597
39	Targeted B: Precision Strike	$\tau = 0.10, \gamma = 0.0, \alpha = 0.15, D = 0.4/S = 0.6$, CSEP, SmartHop2	33.20%	43.72%	28.59	19.2%	0.96s	0.36s	3,566,651
40	T-RAG v1 High-Speed G1	$\tau = 0.30, \gamma = 1.0$, No CSEP, No AdaptTau	33.00%	41.86%	29.15	21.4%	0.93s	1.08s	1,282,848
41	HyDE Baseline	HyDE (Hypothetical Doc Gen) → Hybrid → Rerank	33.00%	42.97%	28.01	18.2%	1.23s	0.63s	4,213,106
42	Ablation: No Smart Hop2	$\tau = 0.15, \gamma = 0.5, \alpha = 0.08, D = 0.5/S = 0.5$, Always Hop2 ON	32.80%	43.93%	29.39	18.6%	1.16s	0.58s	2,681,805
43	Query Expansion Baseline	LLM 3 Sub-queries → Parallel Hybrid → RRF → Rerank	32.60%	43.14%	28.34	19.8%	2.46s	1.91s	4,213,106
44	Targeted A: Ultimate Combo	$\tau = 0.05, \gamma = 0.0, \alpha = 0.15, D = 0.3/S = 0.7$, CSEP, SmartHop2	32.40%	42.77%	28.41	21.4%	1.00s	0.39s	3,591,459
45	T-RAG v1 High-Recall	$\tau = 0.05, \gamma = 0.0$, No CSEP, No AdaptTau	32.40%	43.25%	28.15	19.6%	1.25s	2.28s	3,598,130

Phụ lục (4/4): Bảng Master Kết quả (Cấu hình 46 – 61)

#	Pipeline / Cấu hình	Thông số Cấu hình Details	Corr%	Comp%	Combined	Refused	Total Lat	Retr Lat	Search Space
46	T-RAG v1 Balanced	$\tau = 0.15, \gamma = 0.0$, No CSEP, No AdaptTau	32.40%	42.56%	27.91	19.2%	1.05s	1.53s	2,372,449
47	OPT: Retrieve Depth=10	$\tau = 0.15, \gamma = 0.5, \alpha = 0.08, R = 10, K = 5$, CSEP, SmartHop2	32.40%	42.29%	27.85	22.2%	0.71s	0.16s	2,711,610
48	T-RAG v1 High-Speed	$\tau = 0.30, \gamma = 0.0$, No CSEP, No AdaptTau	32.20%	42.44%	28.36	22.0%	0.92s	1.01s	1,284,666
49	Targeted F: Wide Net Balanced	$\tau = 0.05, \gamma = 0.0, \alpha = 0.08, R = 25, K = 5$, CSEP, SmartHop2	32.20%	43.34%	27.79	19.4%	1.01s	0.42s	3,575,488
50	Targeted E: Low Gamma High Alpha	$\tau = 0.10, \gamma = 0.0, \alpha = 0.12, D = 0.3/S = 0.7$, CSEP, SmartHop2	31.80%	43.46%	28.17	21.2%	1.00s	0.39s	3,483,602
51	T-RAG v1 No Reranker	$\tau = 0.15, \gamma = 0.0$, No Reranker, No CSEP, No AdaptTau	31.80%	40.72%	27.69	20.8%	1.06s	1.66s	2,372,449
52	Targeted C: Gamma Zero Low Tau	$\tau = 0.10, \gamma = 0.0, \alpha = 0.08, D = 0.3/S = 0.7$, CSEP, SmartHop2	31.00%	43.51%	27.55	21.2%	1.00s	0.38s	3,323,775
53	OPT: TopK=3	$\tau = 0.15, \gamma = 0.5, \alpha = 0.08, K = 3$, CSEP, SmartHop2	30.60%	42.06%	27.39	21.6%	0.66s	0.26s	2,711,818
54	BM25 Baseline	Pure BM25, K=5	29.20%	39.50%	25.23	23.0%	0.97s	0.41s	4,213,106
55	Grid Dense=0.7	$\tau = 0.15, \gamma = 0.5, \alpha = 0.08, D = 0.7/S = 0.3$, CSEP, SmartHop2	28.26%	37.18%	24.34	24.0%	0.82s	0.26s	2,704,805
56	LLM Router Baseline	LLM Prompting Router → Hybrid → RRF → Rerank	27.80%	38.57%	23.96	21.8%	0.88s	0.32s	2,075,036
57	Grid Dense=0.9	$\tau = 0.15, \gamma = 0.5, \alpha = 0.08, D = 0.9/S = 0.1$, CSEP, SmartHop2	25.85%	34.83%	22.14	25.4%	0.82s	0.26s	2,704,805
58	VECTOR RERANKER Baseline	Pure Vector → Cross-Encoder Reranker, K=5	24.65%	33.84%	20.89	26.8%	0.69s	0.23s	4,213,106
59	Dense Only	$\tau = 0.15, \gamma = 0.5, \alpha = 0.08, D = 1.0/S = 0.0$, CSEP, SmartHop2	24.25%	34.66%	21.11	26.2%	0.82s	0.25s	2,705,415
60	OPT: TopK=1	$\tau = 0.15, \gamma = 0.5, \alpha = 0.08, K = 1$, CSEP, SmartHop2	22.40%	33.05%	19.63	40.6%	0.48s	0.25s	2,711,818
61	Vector Baseline	Pure Vector, K=5	19.60%	30.24%	16.47	32.0%	0.60s	0.20s	4,213,106