

T-RAG: Targeted Retrieval-Augmented Generation

Probabilistic Source-Aware RAG for Enterprise Data

Trình bày: Đặng Bảo & Đinh Bằng

Research Proposal — Advisor Meeting

Tháng 7, 2026

Outline

- 1 Bối cảnh & Bài toán
- 2 Tính Mới & Đóng góp
- 3 Kiến trúc Pipeline Đề xuất
- 4 Kế hoạch Thực thi Kỹ thuật

Bài toán: RAG trên dữ liệu Doanh nghiệp

Dataset: EnterpriseRAG-Bench

- **511,962 documents** từ 9 nguồn khác nhau
- Slack (285k), Gmail (121k), Jira (41k), Confluence (5k), GitHub, Fireflies...
- **500 câu hỏi** benchmark, 10 loại
- Dữ liệu nhiễu (Noisy Data): Xung đột ngữ nghĩa, trùng lặp thông tin

3 Vấn đề của Standard RAG

- ❶ **Sự mơ hồ về nguồn (Source Ambiguity):** Gây phân tán không gian đặc trưng và tăng độ nhiễu.
- ❷ **Bất đồng từ vựng (Vocabulary Mismatch):** Sự sai lệch giữa ngôn ngữ tự nhiên và thuật ngữ kỹ thuật.
- ❸ **Truy vấn đa nguồn (Multi-source Queries):** Đòi hỏi năng lực suy luận chéo nguồn phức tạp.

Kiến trúc Standard RAG bộc lộ hạn chế về độ phức tạp tính toán và khả năng định chuẩn khi đối sánh trên toàn cục không gian dữ liệu.

3 Đóng góp Học thuật

#1 — Probabilistic Source Router (PSR) + Database Sharding

System-ML Co-design: Tích hợp phân vùng hệ quản trị Vector DB và mô hình dự báo xác suất định tuyến, tối ưu hóa không gian tìm kiếm từ **50–90%**.


#2 — Source-Weighted RRF (SW-RRF)

Cải tiến mô hình toán học: Đề xuất tích hợp **Bayesian Prior** trực tiếp vào công thức Reciprocal Rank Fusion nhằm tối ưu hóa tính điểm xếp hạng tài liệu đa nguồn.

#3 — Cross-Source Entity Propagation (CSEP)

Phương pháp suy luận đa bước: Khắc phục giới hạn truy vấn chéo bằng kỹ thuật trích xuất thực thể mỏ neo (Anchor Entity) để định hướng chuỗi suy luận thứ cấp.

Tổng quan Pipeline T-RAG (4 Giai đoạn)



Xanh = Pre-Retrieval
Phân loại & Định tuyến

Cam = Retrieval
Lai ghép & Suy luận đa bước

Xanh lá = Post-Retrieval
Kiểm soát ảo giác

Giai đoạn 1: Probabilistic Source Router (PSR)

Toán học định tuyến: Dự báo xác suất có điều kiện của nguồn:

$$P(s_i|Q) = \text{Softmax}(W \cdot \text{Encoder}(Q) + b)_i$$

Thuật toán Phân vùng (Sharding):

- Chỉ kích hoạt tìm kiếm trên tập nguồn con:

$$S_{active} = \{s_i \in S \mid P(s_i|Q) \geq \tau\}$$

Kết quả: Độ phức tạp giảm từ $O(|D_{total}|)$ xuống $O(\sum_{i \in S_{active}} |D_{s_i}|)$. Giảm I/O đáng kể.

Ví dụ minh họa định tuyến

Truy vấn: *"What did the team say about the GPU budget meeting?"*

Kết quả phân phối xác suất từ PSR:

- $P(\text{Fireflies}|Q) = 0.81 > \tau \rightarrow$ Kích hoạt
- $P(\text{Slack}|Q) = 0.72 > \tau \rightarrow$ Kích hoạt
- $P(\text{Jira}|Q) = 0.04 \leq \tau \rightarrow$ Loại bỏ
- $P(\text{GitHub}|Q) = 0.02 \leq \tau \rightarrow$ Loại bỏ

Giai đoạn 2: Source-Weighted RRF (SW-RRF)

RRF truyền thống (Cormack, 2009): Đánh đồng mọi tài liệu, làm mất đi sự "ưu tiên" cho nguồn chính.

Đề xuất tính mới (SW-RRF): Đưa xác suất $P(s_d|Q)$ làm **Bayesian Prior** vào công thức xếp hạng.

$$\text{Score}(d) = P(s_d|Q)^\gamma \cdot \left(\frac{\alpha}{k + r_{\text{dense}}} + \frac{1 - \alpha}{k + r_{\text{sparse}}} \right)$$

- γ : Source Bias Factor
- α : Trọng số Dense/Sparse

Cơ sở lý thuyết của SW-RRF

Tối ưu hóa thứ hạng tài liệu mục tiêu thông qua trọng số phân phối xác suất ($P(s_d|Q)$), triệt tiêu nhiễu từ các văn bản có tính tương đồng bề mặt nhưng sai lệch ngữ cảnh nguồn.

Khả năng hỗ trợ của Hybrid Search

- **Dense Search:** Trích xuất và đối sánh biểu diễn ngữ nghĩa trừu tượng.
- **Sparse (BM25):** Ràng buộc tính chính xác từ vựng (Exact match).

Giai đoạn 3 & 4: Multi-hop & Reranking

Giai đoạn 3: CSEP (Suy luận đa bước)

Mô phỏng cơ chế đồ thị hai phía (Bipartite Graph Random Walk).

- ➊ **Hop 1:** Khởi tạo truy xuất trên nguồn tối ưu nhất $\rightarrow$ Định vị tài liệu mỏ neo (D_{anchor}).
- ➋ **Entity Extraction:** Phân tách và nhận diện tập thực thể E từ D_{anchor} .
- ➌ **Hop 2:** Mở rộng không gian truy vấn $Q^{(2)} = Q \oplus E$ để đối sánh chéo nguồn.

Giai đoạn 4: Kiểm soát ngưỡng tin cậy

Sử dụng **Cross-Encoder** tối ưu hóa hàm đánh giá $CE(Q, d_{final})$.

Áp dụng **Hard Thresholding**: Lọc nhiễu triệt để nếu $CE(Q, d) < \theta$.

Trong điều kiện $D_{final} = \emptyset$, hệ thống ngắt luồng LLM và trả về "Unanswerable", hỗ trợ giảm thiểu hiện tượng ảo giác (Hallucination).

Kế hoạch Thực thi & Đánh giá

Các bước Triển khai

- ➊ **Tiền xử lý Dữ liệu:** Áp dụng mô hình Sharding chia 511k documents thành các bảng phân mảnh độc lập theo `source_type`.
- ➋ **Huấn luyện PSR Router:** Tinh chỉnh (Fine-tune) mô hình Encoder gọn nhẹ thành bộ phân loại xác suất (Soft Classifier).
- ➌ **Triển khai SW-RRF:** Xây dựng hàm lai ghép truy xuất (Retriever) tích hợp công thức toán học hệ số.

Đánh giá (So với Standard RAG)

- **Chất lượng:** Recall@K, NDCG@10 (sử dụng tập ground truth)
- **Tốc độ/Chi phí:** Latency (ms), Search Space Size (% documents được load)

Tài liệu Tham khảo (Verified References) I

- ❶ Qiao et al. (2024). *Route Before Retrieve: A New Paradigm for Retrieval-Augmented Generation*.
- ❷ Wang et al. (2024). *RAGRouter: Learning to Route in Retrieval-Augmented Generation*. NeurIPS 2024.
- ❸ Cormack, G. V., Clarke, C. L., & Büttcher, S. (2009). *Reciprocal rank fusion outperforms Condorcet and individual rank learning methods*. ACM SIGIR.
- ❹ Tang et al. (2024). *MultiHop-RAG: Benchmarking Retrieval-Augmented Generation for Multi-Hop Queries*. arXiv:2401.15391.
- ❺ Zhang et al. (2025). *HopRAG: Multi-Hop Reasoning for Logic-Aware Retrieval-Augmented Generation*. arXiv:2502.12442.
- ❻ Nogueira, R., & Cho, K. (2019). *Passage Re-ranking with BERT*. arXiv:1901.04085.