

T-RAG: Targeted Retrieval-Augmented Generation

Probabilistic Source-Aware RAG for Enterprise Data

Trình bày: Đặng Bảo & Đinh Bằng

Research Proposal — Advisor Meeting

Tháng 7, 2026

- 1 Bối cảnh & Bài toán
- 2 Tính Mới & Đóng góp (Academic Novelty)
- 3 Kiến trúc Pipeline Đề xuất
- 4 Kế hoạch Thực thi Kỹ thuật

Bài toán: RAG trên dữ liệu Doanh nghiệp

Dataset: EnterpriseRAG-Bench

- **511,962 documents** từ 9 nguồn khác nhau
- Slack (285k), Gmail (121k), Jira (41k), Confluence (5k), GitHub, Fireflies...
- **500 câu hỏi** benchmark, 10 loại
- Dữ liệu "messy": xung đột, trùng lặp, ngôn ngữ kỹ thuật

3 Vấn đề của Standard RAG

- 1 **Source Ambiguity & Vector Density:** Không phân biệt nguồn làm không gian tìm kiếm khổng lồ
- 2 **Vocabulary Mismatch:** Truy vấn tự nhiên vs. mã lỗi, thuật ngữ (PR 482, PROJ-102)
- 3 **Multi-source Queries:** Câu hỏi yêu cầu thông tin chéo nguồn

Standard RAG tìm kiếm mù quáng trên 511k documents — tốn kém, thiếu chính xác.

3 Đóng góp Học thuật (Novelty)

#1 — Probabilistic Source Router (PSR) + Database Sharding

System-ML Co-design: Phân vùng vật lý Vector DB theo nguồn. PSR dự đoán xác suất định tuyến, giúp giảm không gian tìm kiếm (Search Space) từ **50–90%**.


#2 — Source-Weighted RRF (SW-RRF)

Đề xuất toán học mới: Tích hợp **Bayesian Prior** (xác suất nguồn) trực tiếp vào công thức Reciprocal Rank Fusion truyền thống để tối ưu lai ghép đa nguồn.

#3 — Cross-Source Entity Propagation (CSEP)

Thuật toán Multi-hop mới: Giải quyết bài toán truy vấn chéo nguồn bằng cách lấy thông tin mỏ neo (Anchor) từ một nguồn để mở rộng tìm kiếm sang nguồn khác.

Tổng quan Pipeline T-RAG (4 Giai đoạn)



Xanh = Pre-Retrieval
Định tuyến & Thu hẹp

Cam = Retrieval
Tìm kiếm lai & Multi-hop

Xanh lá = Post-Retrieval
Đánh giá độ tin cậy

Giai đoạn 1: Probabilistic Source Router (PSR)

Toán học định tuyến: Dự báo xác suất có điều kiện của nguồn:

$$P(s_i|Q) = \text{Softmax}(W \cdot \text{Encoder}(Q) + b)_i$$

Thuật toán Phân vùng (Sharding):

- Chỉ kích hoạt tìm kiếm trên tập nguồn con:

$$S_{\text{active}} = \{s_i \in S \mid P(s_i|Q) \geq \tau\}$$

Kết quả: Độ phức tạp giảm từ $O(|D_{\text{total}}|)$ xuống $O(\sum_{i \in S_{\text{active}}} |D_{s_i}|)$. Giảm I/O đáng kể.

Ví dụ

Truy vấn: *"What did the team say about the GPU budget meeting?"*

PSR output:

- $P(\text{Fireflies}|Q) = 0.81 \rightarrow$ Chọn
- $P(\text{Slack}|Q) = 0.72 \rightarrow$ Chọn
- $P(\text{Jira}|Q) = 0.04 \rightarrow$ Bỏ
- $P(\text{GitHub}|Q) = 0.02 \rightarrow$ Bỏ

Giai đoạn 2: Source-Weighted RRF (SW-RRF)

RRF truyền thống (Cormack, 2009): Đánh đồng mọi tài liệu, làm mất đi sự "ưu tiên" cho nguồn chính.

Đề xuất tính mới (SW-RRF): Đưa xác suất $P(s_d|Q)$ làm **Bayesian Prior** vào công thức xếp hạng.

$$\text{Score}(d) = P(s_d|Q)^\gamma \cdot \left(\frac{\alpha}{k + r_{\text{dense}}} + \frac{1 - \alpha}{k + r_{\text{sparse}}} \right)$$

- γ : Source Bias Factor
- α : Trọng số Dense/Sparse

Tại sao SW-RRF hiệu quả?

Tài liệu thuộc nguồn có xác suất cao (từ PSR) sẽ được "**boost**" điểm toán học. Ép các tài liệu đúng nguồn trôi lên top, đánh bại các tài liệu đồng nghĩa nhưng nằm sai nguồn.

Sự cần thiết của Hybrid

- **Dense Search:** Khớp ngữ nghĩa
- **Sparse (BM25):** Bắt chính xác (Exact match)

Giai đoạn 3 & 4: Multi-hop & Reranking

Giai đoạn 3: CSEP (Multi-hop)

Dành cho truy vấn đa nguồn phức tạp.

- 1 **Hop 1:** Tìm trên nguồn có $P(s|Q)$ cao nhất → Lấy tài liệu mỏ neo (D_{anchor}).
- 2 **Entity Extract:** Trích xuất thực thể E từ D_{anchor} .
- 3 **Hop 2:** Cập nhật truy vấn $Q^{(2)} = Q \oplus E$, tìm trên nguồn thứ 2.

Giai đoạn 4: Đánh giá độ tin cậy

Dùng **Cross-Encoder** tính toán hàm liên kết $CE(Q, d_{final})$.

Áp dụng **Hard Thresholding**: Lọc bỏ tài liệu nếu $CE(Q, d) < \theta$.

Nếu rỗng → Trả về "Unanswerable" → **Giảm Hallucination triệt để!**

Các bước Triển khai

- ➊ **Chuẩn bị Dữ liệu:** Sharding 511k documents thành các bảng độc lập trong **LanceDB** theo `source_type`.
- ➋ **Train PSR Router:** Fine-tune LLM nhỏ (Llama-3-8B hoặc BERT) để làm bộ Classifier.
- ➌ **Cài đặt SW-RRF:** Lập trình hàm Retriever theo đúng phương trình toán học đã đề xuất.

Đánh giá (So với Standard RAG)

- **Chất lượng:** Recall@K, NDCG@10 (sử dụng tập ground truth)
- **Tốc độ/Chi phí:** Latency (ms), Search Space Size (% documents được load)

Tài liệu Tham khảo (Verified References) I

- ❸ Qiao et al. (2024). *Route Before Retrieve: A New Paradigm for Retrieval-Augmented Generation*.
- ❹ Wang et al. (2024). *RAGRouter: Learning to Route in Retrieval-Augmented Generation*. NeurIPS 2024.
- ❺ Cormack, G. V., Clarke, C. L., & Büttcher, S. (2009). *Reciprocal rank fusion outperforms Condorcet and individual rank learning methods*. ACM SIGIR.
- ❻ Tang et al. (2024). *MultiHop-RAG: Benchmarking Retrieval-Augmented Generation for Multi-Hop Queries*. arXiv:2401.15391.
- ❼ Zhang et al. (2025). *HopRAG: Multi-Hop Reasoning for Logic-Aware Retrieval-Augmented Generation*. arXiv:2502.12442.
- ❽ Nogueira, R., & Cho, K. (2019). *Passage Re-ranking with BERT*. arXiv:1901.04085.